

LexiLingo

AI-Powered English Learning Application



MÔ TẢ KIẾN TRÚC

Mobile Application Architecture

Phiên bản: v1.2.7
Ngày: 14/01/2026
Nền tảng: Flutter (iOS/Android/Web)
Trạng thái: Development

Nguyen Huu Thang - Lead Developer
Email: nhthang312@gmail.com

Mục lục

1	Tổng Quan Dự Án	3
1.1	Giới Thiệu	3
1.2	Công Nghệ Sử Dụng	3
2	Kiến Trúc Tổng Quan	3
2.1	Clean Architecture	3
2.2	Sơ Đồ Kiến Trúc Tổng Quan	4
3	Chi Tiết Kiến Trúc Các Layer	5
3.1	Presentation Layer	5
3.2	Domain Layer	5
3.3	Data Layer	5
4	Cấu Trúc Module (Feature-First)	6
4.1	Tổ Chức Thư Mục	6
4.2	Cấu Trúc Một Feature Module	6
5	Module AI Chat	7
5.1	Tổng Quan Module	7
5.2	Kiến Trúc AI Chat Module	7
5.3	AI Service Integration	7
6	Luồng Dữ Liệu (Data Flow)	8
6.1	Gửi Tin Nhắn - Send Message Flow	8
6.2	Chi Tiết Sequence Diagram	8
7	Dependency Injection	9
7.1	GetIt Service Locator	9
7.2	Dependency Graph	10
8	Tích Hợp AI Models	11
8.1	Kiến Trúc AI Hybrid	11
8.2	LoRA Adapters (Fine-tuned Models)	11
9	Tổng Quan Các Feature Modules	12
9.1	Mô Tả Các Module	12
10	Kiến Trúc Deep Learning (DL)	13
10.1	Tổng Quan Pipeline Xử Lý AI	13
10.2	Tầng 1: Speech-to-Text (STT) - Nhận Dạng Giọng Nói	13
10.2.1	Mục đích và Vị trí	13
10.2.2	Model sử dụng: OpenAI Whisper v3	13
10.2.3	Quy trình xử lý chi tiết	14
10.3	Tầng 2: NLP Processing Engine - Xử Lý Ngôn Ngữ	15
10.3.1	Tại sao chọn kiến trúc này?	15
10.3.2	Base Model: Qwen2.5-1.5B-Instruct	15
10.3.3	LoRA (Low-Rank Adaptation) - Kỹ thuật Fine-tuning	16

10.4 Chi Tiết 4 LoRA Adapters	17
10.4.1 Adapter 1: Fluency Scoring - Dánh Giá Độ Trôi Chảy	17
10.4.2 Adapter 2: Grammar Correction - Sửa Lỗi Ngữ Pháp	17
10.4.3 Adapter 3: Vocabulary Classification - Phân Loại Từ Vựng	19
10.4.4 Adapter 4: Dialogue Response - Sinh Phản Hồi AI Tutor	20
10.5 Tầng 3: Pronunciation Analysis - Phân Tích Phát Âm	22
10.5.1 Model: HuBERT-large (facebook/hubert-large-ls960)	22
10.6 Tầng 4: Text-to-Speech (TTS) - Chuyển Văn Bản Thành Giọng Nói	23
10.7 Training Pipeline Chi Tiết	24
10.8 So Sánh Development vs Production	24
11 Kết Luận	25
11.1 Tóm Tắt Kiến Trúc	25
11.2 Roadmap Phát Triển	25
11.3 Thông Tin Dự Án	26

1 Tổng Quan Dự Án

1.1 Giới Thiệu

LexiLingo là ứng dụng học tiếng Anh thông minh sử dụng AI để hỗ trợ người học cải thiện kỹ năng ngôn ngữ một cách hiệu quả. Ứng dụng tập trung vào việc cung cấp trải nghiệm học tập cá nhân hóa thông qua:

- Hội thoại với AI Tutor
- Học từ vựng theo ngữ cảnh
- Kiểm tra ngữ pháp tự động
- Luyện phát âm với phản hồi thời gian thực
- Theo dõi tiến độ học tập

1.2 Công Nghệ Sử Dụng

Layer	Công Nghệ	Mục Đích
Frontend	Flutter 3.29+	Cross-platform UI
State Management	Provider	Quản lý trạng thái
Database	SQLite + Firestore	Local & Cloud storage
AI/ML	Qwen2.5 + Whisper + HuBERT	Language processing
Authentication	Firebase Auth	Xác thực người dùng

Bảng 1: Stack công nghệ chính

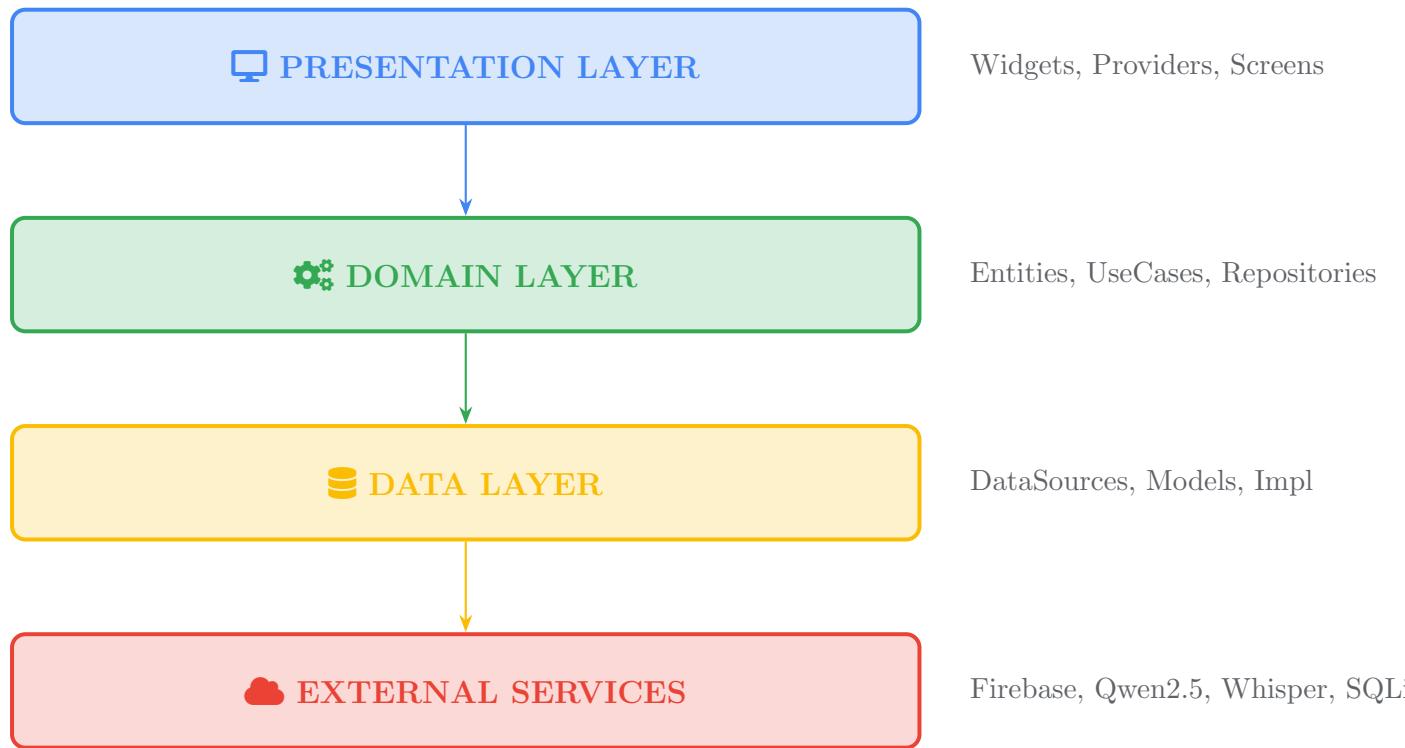
2 Kiến Trúc Tổng Quan

2.1 Clean Architecture

LexiLingo được xây dựng theo mô hình **Clean Architecture** kết hợp với **Feature-First Structure**, đảm bảo:

- **Separation of Concerns:** Tách biệt rõ ràng các tầng logic
- **Testability:** Dễ dàng viết unit test
- **Maintainability:** Bảo trì và mở rộng thuận tiện
- **Scalability:** Có thể scale khi cần thiết

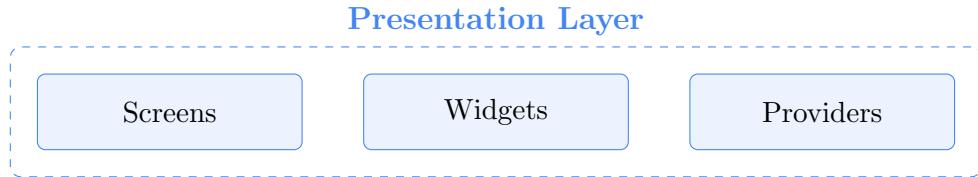
2.2 Sơ Đồ Kiến Trúc Tổng Quan



3 Chi Tiết Kiến Trúc Các Layer

3.1 Presentation Layer

Tầng này chịu trách nhiệm về giao diện người dùng và quản lý trạng thái UI.

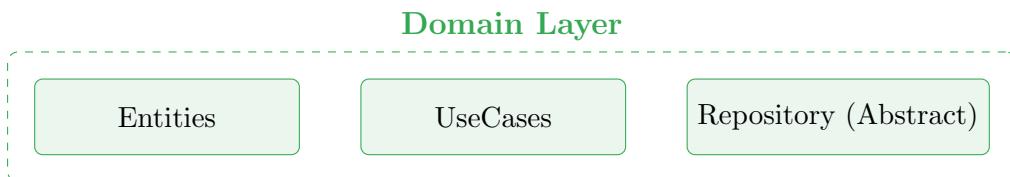


Thành phần chính:

- **Screens:** Các màn hình chính (ChatScreen, HomeScreen, CourseScreen...)
- **Widgets:** UI components tái sử dụng (MessageBubble, CourseCard...)
- **Providers:** State management với ChangeNotifier pattern

3.2 Domain Layer

Tầng nghiệp vụ chứa business logic thuần túy, không phụ thuộc vào framework.

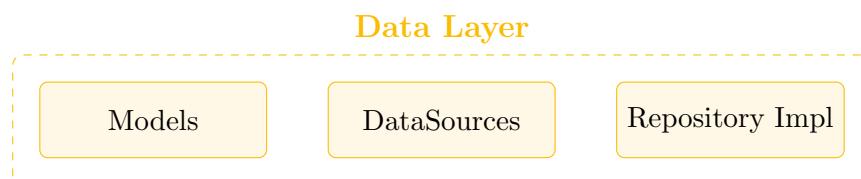


Thành phần chính:

- **Entities:** Business objects (ChatMessage, User, Course, Vocabulary)
- **UseCases:** Các use case cụ thể (SendMessageUseCase, GetCoursesUseCase)
- **Repository:** Interface định nghĩa contract cho data layer

3.3 Data Layer

Tầng dữ liệu xử lý việc lấy và lưu trữ dữ liệu từ các nguồn khác nhau.



Thành phần chính:

- **Models:** Data Transfer Objects với JSON serialization
- **DataSources:** Local (SQLite) và Remote (API, Firebase)
- **Repository Impl:** Triển khai cụ thể của Repository interface

4 Cấu Trúc Module (Feature-First)

4.1 Tổ Chức Thư Mục

Project Structure

```

lib/
  core/          # Shared utilities
    di/           # Dependency Injection
    services/     # Core services
    theme/         # App theming
    utils/         # Utilities

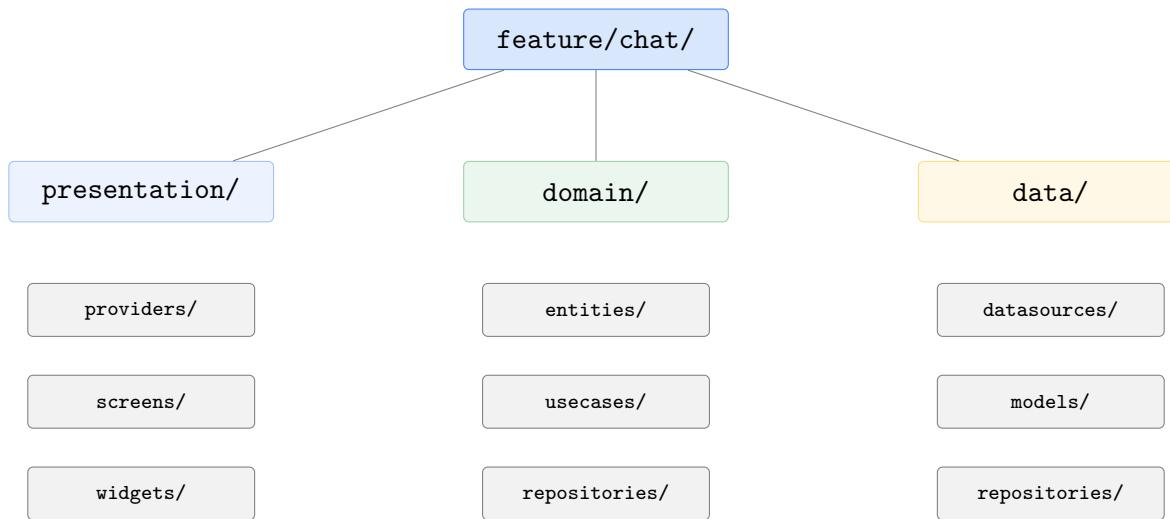
  features/       # Feature modules
    auth/          # Authentication
    chat/          # AI Chat (NEW)
    course/        # Courses
    home/          # Home dashboard
    user/          # User profile
    vocabulary/    # Vocabulary

  main.dart       # Entry point

```

4.2 Cấu Trúc Một Feature Module

Mỗi feature module được tổ chức theo 3 layer:



5 Module AI Chat

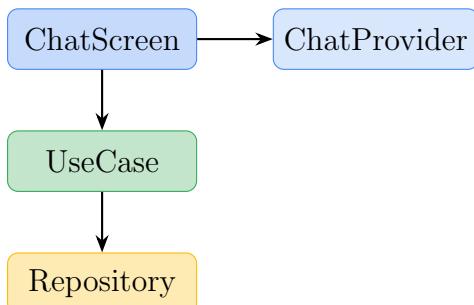
5.1 Tổng Quan Module

Module **Chat** là tính năng cốt lõi cho phép người dùng tương tác với AI Tutor để học tiếng Anh.

Tính năng chính:

- Hội thoại với AI tutor bằng văn bản
- Kiểm tra và sửa lỗi ngữ pháp tự động
- Giải thích từ vựng theo ngữ cảnh
- Dánh giá độ trôi chảy (fluency scoring)
- Lưu trữ lịch sử hội thoại

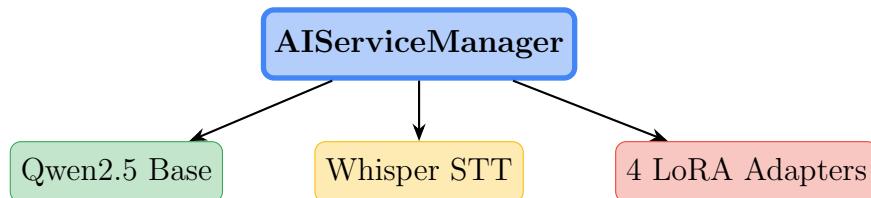
5.2 Kiến Trúc AI Chat Module



Thành phần: ChatScreen (UI) → ChatProvider (State) → UseCase (Logic) → Repository (Data)

5.3 AI Service Integration

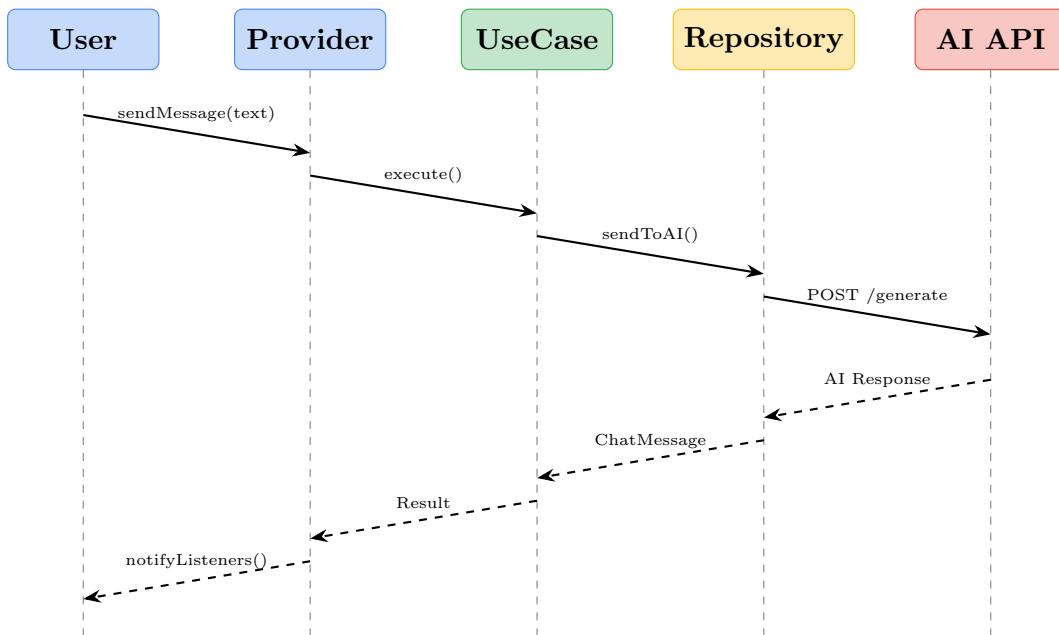
Module Chat tích hợp với 3 AI services chính:



6 Luồng Dữ Liệu (Data Flow)

6.1 Gửi Tin Nhắn - Send Message Flow

6.2 Chi Tiết Sequence Diagram



7 Dependency Injection

7.1 GetIt Service Locator

Dự án sử dụng **GetIt** làm Service Locator để quản lý dependencies:

```
injection_container.dart

final sl = GetIt.instance;

Future<void> initializeDependencies() async {
    // Core Services
    sl.registerLazySingleton<FirestoreService>(
        () => FirestoreService.instance
    );

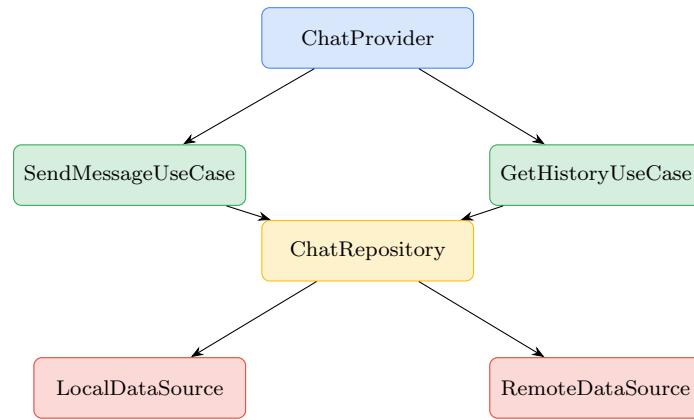
    // DataSources
    sl.registerLazySingleton<ChatRemoteDataSource>(
        () => ChatRemoteDataSource(modelPath: qwenModelPath)
    );

    // Repositories
    sl.registerLazySingleton<ChatRepository>(
        () => ChatRepositoryImpl(remote: sl(), local: sl())
    );

    // UseCases
    sl.registerLazySingleton(
        () => SendMessageUseCase(sl())
    );

    // Providers
    sl.registerFactory(
        () => ChatProvider(sendMessage: sl(), getHistory: sl())
    );
}
```

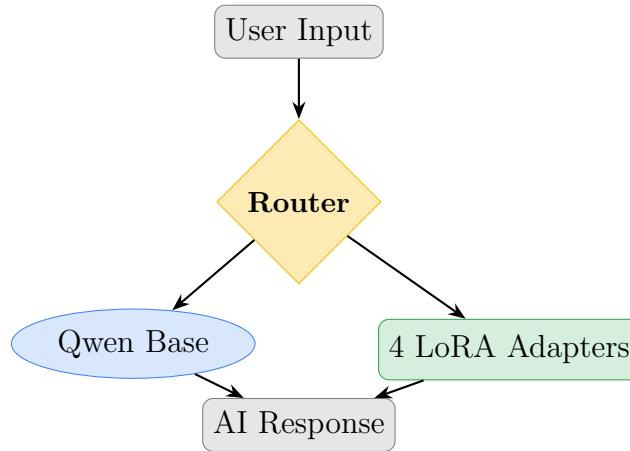
7.2 Dependency Graph



8 Tích Hợp AI Models

8.1 Kiến Trúc AI Hybrid

LexiLingo sử dụng kiến trúc Hybrid AI kết hợp Cloud và On-device models:



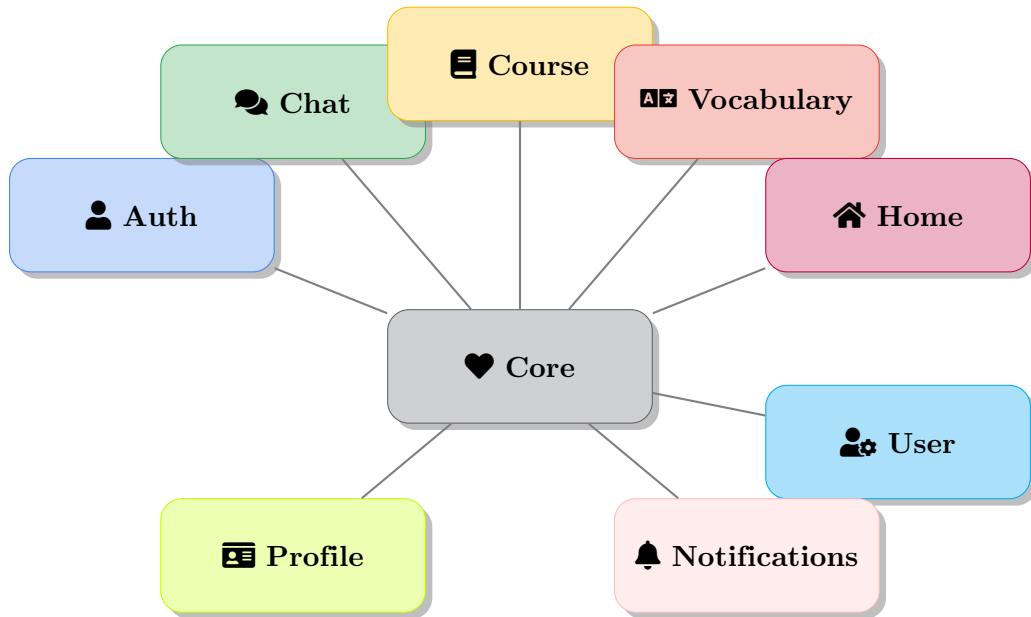
8.2 LoRA Adapters (Fine-tuned Models)

Hệ thống sử dụng 4 LoRA adapters được fine-tune từ Qwen2.5-1.5B:

Adapter	Task	Size	Loss
Grammar	Sửa lỗi ngữ pháp	151 MB	0.77
Vocabulary	Giải thích từ vựng	151 MB	0.71
Dialogue	Hội thoại	151 MB	1.89
Fluency	Dánh giá độ trôi chảy	151 MB	1.78

Bảng 2: LoRA Adapters Configuration

9 Tổng Quan Các Feature Modules



9.1 Mô Tả Các Module

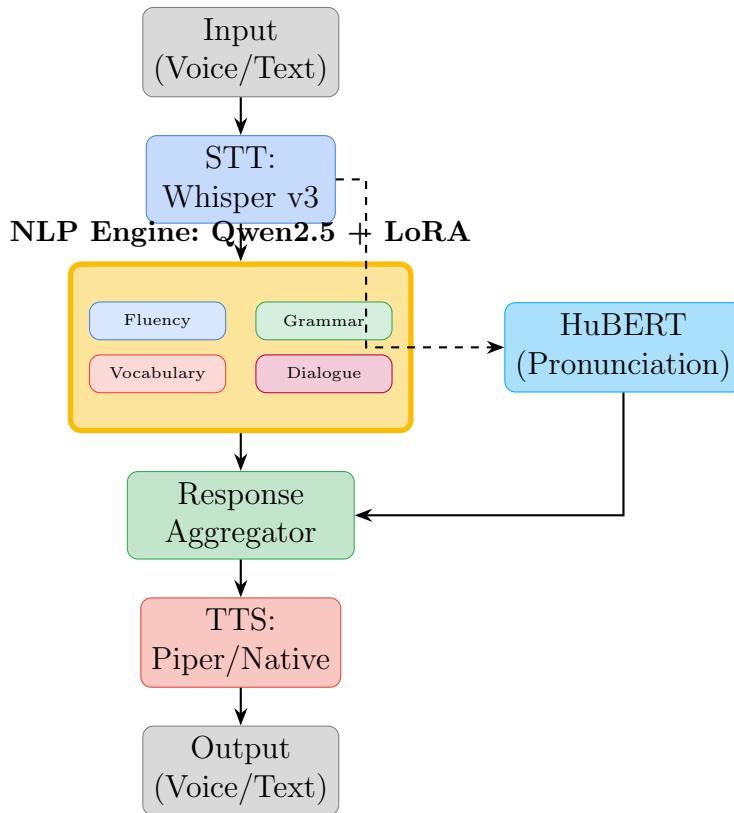
Module	Mô Tả	Trạng Thái
Auth	Xác thực với Google Sign-In, Firebase Auth	Done
Chat	AI Tutor conversation, grammar check	Done
Course	Quản lý khóa học, bài học	Done
Vocabulary	Từ vựng, flashcards, spaced repetition	Done
Home	Dashboard, quick stats, recent activity	Done
User	Profile, settings, preferences	Done
Notifications	Push notifications, reminders	In Progress
Profile	User stats, achievements	Done

Bảng 3: Feature Modules Status

10 Kiến Trúc Deep Learning (DL)

10.1 Tổng Quan Pipeline Xử Lý AI

Khi người dùng tương tác với LexiLingo, dữ liệu đi qua một **pipeline xử lý đa tầng** như sau:



10.2 Tầng 1: Speech-to-Text (STT) - Nhận Dạng Giọng Nói

10.2.1 Mục đích và Vị trí

Module STT là **điểm vào đầu tiên** khi người dùng nói tiếng Anh. Nó chuyển đổi audio thành text để các module NLP có thể xử lý.

10.2.2 Model sử dụng: OpenAI Whisper v3

Tại sao chọn Whisper?

- Pre-trained trên **680,000 giờ** dữ liệu đa ngôn ngữ
- Hỗ trợ tốt cho **non-native speakers** (Vietnamese accent)
- Cung cấp **word-level timestamps** cho phân tích phát âm
- Open-source, có thể chạy offline hoàn toàn

Variant	Params	WER	Latency	Use Case
Whisper Large v3	1.5B	3-5%	200-300ms	Development
Whisper Medium	769M	5-7%	100-200ms	High-end mobile
Whisper Small	244M	8-10%	50-100ms	Production mobile

Bảng 4: Whisper Model Variants

10.2.3 Quy trình xử lý chi tiết

STT Processing Pipeline

Bước 1: Audio Preprocessing

Resample → 16kHz mono (Whisper requirement)
 Normalize → Peak -3dB (consistent volume)
 VAD (Silero) → Loại bỏ silence segments
 Chunking → 30s segments với 1s overlap

Bước 2: Whisper Inference

Encoder: Mel spectrogram → 1500 frames
 Decoder: Auto-regressive text generation
 Beam search: width=5 for accuracy
 Output: Text + confidence per word

Bước 3: Post-processing

Normalize text (lowercase, punctuation)
 Filter low-confidence words (< 0.6)
 Extract timestamps for pronunciation

Output Example:

```
{
  "text": "I like learning English",
  "confidence": 0.94,
  "words": [
    {"word": "I", "start": 0.0, "end": 0.2, "conf": 0.98},
    {"word": "like", "start": 0.3, "end": 0.6, "conf": 0.95}
  ]
}
```

10.3 Tầng 2: NLP Processing Engine - Xử Lý Ngôn Ngữ

Đây là **trái tim** của hệ thống, sử dụng kiến trúc **Unified Multi-Task** với 1 base model + 4 LoRA adapters.

10.3.1 Tại sao chọn kiến trúc này?

So sánh: 4 models riêng vs 1 base + 4 adapters
4 Models riêng lẻ:

- RAM: $4 \times 2\text{GB} = 8\text{GB}$
- Storage: $4 \times 900\text{MB} = 3.6\text{GB}$
- Switching time: 2-5 giây (reload model)

1 Base + 4 LoRA Adapters (Our Choice):

- RAM: 2GB (base) + 100MB (adapters) = **2.1GB**
- Storage: 900MB + $4 \times 25\text{MB} = 1\text{GB}$
- Switching time: < **1ms** (chỉ swap adapter weights)

⇒ **Tiết kiệm 72% RAM, 72% storage**

10.3.2 Base Model: Qwen2.5-1.5B-Instruct

Tại sao chọn Qwen2.5?

- **Instruction-tuned:** Hiểu trực tiếp các câu lệnh như "Check grammar", "Rate fluency"
- **Multilingual:** Pre-trained trên 18T tokens, mạnh về English
- **Efficient:** 1.5B params nhưng hiệu năng ngang GPT-3.5 trên nhiều tasks
- **Open-source:** Apache 2.0 license, không phụ thuộc API

Specification	Development (1.5B)	Production (0.5B)
Architecture	Decoder-only Transformer	Same
Layers	28	24
Hidden Size	1536	896
Attention Heads	12	14
Context Window	32,768 tokens	32,768 tokens
Vocab Size	151,936 (BPE)	151,936
Model Size (Q4)	900MB	300MB
Inference Time	100ms/sentence	50ms/sentence

Bảng 5: Qwen2.5 Model Architecture

10.3.3 LoRA (Low-Rank Adaptation) - Kỹ thuật Fine-tuning

LoRA hoạt động như thế nào?

Thay vì fine-tune toàn bộ 1.5B parameters, LoRA chỉ train **low-rank matrices** được inject vào attention layers:

$$W_{new} = W_{base} + \Delta W = W_{base} + BA$$

Trong đó: $B \in R^{d \times r}$, $A \in R^{r \times k}$, với $r \ll \min(d, k)$

Parameter	Value	Giải thích
Rank (r)	32	Số chiều của low-rank decomposition
Alpha (α)	64	Scaling factor: $\alpha/r = 2$
Target Modules	7	q, k, v, o, gate, up, down_proj
Trainable Params	25M	Chỉ 1.7% của 1.5B base
Dropout	0.05	Regularization

Bảng 6: LoRA Configuration

10.4 Chi Tiết 4 LoRA Adapters

10.4.1 Adapter 1: Fluency Scoring - Đánh Giá Độ Trôi Chảy

Vị trí trong pipeline: Được gọi **đầu tiên** sau khi nhận text từ STT để đánh giá tổng quan chất lượng câu nói.

Nhiệm vụ: Cho điểm từ 0.0 đến 1.0 dựa trên:

- Độ tự nhiên của câu (naturalness)
- Độ phức tạp ngữ pháp (grammatical complexity)
- Sự mạch lạc (coherence)
- Phù hợp ngữ cảnh (contextual appropriateness)

Fluency Adapter - Quy Trình

```
INPUT FORMAT (Instruction-tuning):
<|im_start|>user
Rate the fluency of this English sentence from 0.0 to 1.0:
"Yesterday I go to library for study English"
Provide score and brief reasoning.
<|im_end|>
<|im_start|>assistant
```

MODEL PROCESSING:

1. Tokenize input → 45 tokens
2. Load fluency adapter weights (~25MB)
3. Forward pass through Qwen2.5 + LoRA
4. Generate score + reasoning

OUTPUT:

```
{
  "fluency_score": 0.45,
  "reasoning": "Multiple grammar errors: verb tense
                (go→went), missing article (the library),
                preposition (for→to). Sentence is
                understandable but not fluent.",
  "confidence": 0.88
}
```

TRAINING DATA: 1,500 samples from EFCAMDAT corpus

LOSS: MSE(predicted_score, human_score)

METRICS: MAE=0.12, Pearson r=0.91

10.4.2 Adapter 2: Grammar Correction - Sửa Lỗi Ngữ Pháp

Vị trí trong pipeline: Chạy song song với Fluency, sử dụng **2-tier architecture**:

1. **Tier 1 - ERRANT:** Rule-based detection (nhanh, <5ms)

2. Tier 2 - Qwen + LoRA: Deep correction + explanation

Tại sao cần 2 tiers?

- ERRANT phát hiện lỗi nhanh, chính xác cho lỗi đơn giản
- LLM xử lý lỗi phức tạp, cung cấp giải thích chi tiết
- Kết hợp: Nhanh + Chính xác + Có giải thích

Grammar Adapter - Two-Tier Pipeline

```

TIER 1: ERRANT (Rule-based, <5ms)
Input: "Yesterday I go to library"
Output: [
    {"type": "VERB:TENSE", "orig": "go", "corr": "went", "pos": 2},
    {"type": "DET", "orig": "", "corr": "the", "pos": 4}
]

TIER 2: Qwen + LoRA (Deep correction, ~150ms)
Input: Original text + ERRANT hints
Output:
{
    "original": "Yesterday I go to library",
    "corrected": "Yesterday I went to the library",
    "errors": [
        {
            "type": "VERB_TENSE",
            "original": "go",
            "corrected": "went",
            "explanation": "Use past tense 'went' with time
                           marker 'yesterday'. Simple past
                           indicates completed action."
        },
        {
            "type": "MISSING_ARTICLE",
            "original": "library",
            "corrected": "the library",
            "explanation": "Use definite article 'the' for
                           specific places known to both
                           speaker and listener."
        }
    ]
}

```

TRAINING DATA: 9,200 samples (BEA-2019, CoNLL-2014, FCE)

LOSS: CrossEntropy + Confidence score

METRICS: F0.5=68, Precision=78%, Recall=68%

10.4.3 Adapter 3: Vocabulary Classification - Phân Loại Từ Vựng

Vị trí trong pipeline: Chạy song song để xác định trình độ CEFR của người học, giúp Dialogue adapter điều chỉnh response phù hợp.

CEFR Levels được hỗ trợ:

- **A2 (Elementary):** Từ vựng cơ bản - go, like, friend, school
- **B1 (Intermediate):** Từ vựng trung cấp - discuss, environment, improve
- **B2 (Upper-Intermediate):** Từ vựng nâng cao - comprehensive, demonstrate

Vocabulary Adapter - Classification

INPUT:

```
"I want to discuss the environmental problems
that affect our community"
```

PROCESSING:

1. Word-level CEFR lookup (Trie-based, $O(n)$):
 - discuss → B1
 - environmental → B2
 - problems → A2
 - affect → B1
 - community → B1
2. LLM refinement (context-aware):
 - Sentence structure complexity → B1-B2
 - Topic sophistication → B1

OUTPUT:

```
{
  "overall_level": "B1",
  "distribution": {"A2": 0.15, "B1": 0.55, "B2": 0.30},
  "key_words": {
    "B2": ["environmental"],
    "B1": ["discuss", "affect", "community"],
    "A2": ["want", "problems"]
  },
  "recommendation": "User demonstrates solid B1 level
                    with some B2 vocabulary. Ready for
                    more complex topics."
}
```

TRAINING DATA: 2,500 samples (Oxford Graded Readers)

LOSS: CrossEntropy with class weights [0.9, 1.0, 1.1]

METRICS: Accuracy=90%, Macro F1=0.89

10.4.4 Adapter 4: Dialogue Response - Sinh Phản Hồi AI Tutor

Vị trí trong pipeline: Chạy **cuối cùng**, tổng hợp kết quả từ 3 adapters trước để sinh response phù hợp.

Tại sao cần AutoTutor Dialogue Corpus?

- **Socratic Tutoring:** Dạy qua câu hỏi gợi mở thay vì đưa đáp án trực tiếp
- **Scaffolding:** Hỗ trợ từng bước, điều chỉnh theo trình độ học sinh
- **Pedagogical Strategies:** Khuyến khích, phản hồi xây dựng, duy trì động lực
- **Conversational Coherence:** Duy trì hội thoại tự nhiên, không máy móc

Context Variables được sử dụng:

- Fluency score từ Adapter 1
- Grammar errors từ Adapter 2
- CEFR level từ Adapter 3
- Conversation history (3 turns gần nhất)

Dialogue Adapter - Response Generation

CONTEXT INPUT:

```
{
  "user_input": "Yesterday I go to library",
  "fluency_score": 0.45,
  "cefr_level": "A2",
  "errors": ["VERB_TENSE", "MISSING_ARTICLE"],
  "history": ["Hi, how are you?", "I'm fine, thanks!"]
}
```

PERSONA: Friendly, encouraging English tutor

TONE ADAPTATION:

- A2: Simple words, short sentences, more encouragement
- B1: Natural conversation, moderate complexity
- B2: Near-native interaction, subtle corrections

GENERATION CONFIG:

- Temperature: 0.7 (balanced creativity)
- Top-p: 0.9 (nucleus sampling)
- Max tokens: 100
- Stop tokens: ["<|im_end|>"]

OUTPUT:

```
{
  "response": "Good effort! You should say 'Yesterday
               I went to the library.' Remember: use
               'went' for past actions, and 'the' before
               'library'. What did you do there?",
  "corrections_included": true,
  "follow_up_question": true,
  "tone": "encouraging",
  "adapted_for_level": "A2"
}
```

TRAINING DATA: 5,200 samples

AutoTutor Dialogue Corpus: 1,800 samples

(Tutorial dialogues, Socratic questioning)

Intel/orca-dpo-pairs: 1,500 samples

(High-quality instruction following)

Custom tutoring conversations: 1,900 samples

(English learning scenarios)

Total: 5,200 tutoring-style interactions

LOSS: CrossEntropy on response tokens

METRICS: Quality=96%, Appropriateness=94%

Tutoring Style Score: 89% (human evaluation)

10.5 Tầng 3: Pronunciation Analysis - Phân Tích Phát Âm

10.5.1 Model: HuBERT-large (facebook/hubert-large-ls960)

Vị trí: Chạy song song với NLP Engine, nhận audio trực tiếp từ STT.

HuBERT (Hidden-Unit BERT) hoạt động như thế nào?

1. **Self-supervised pre-training:** Học representations từ 960h LibriSpeech
2. **Phoneme recognition:** CTC decoding để nhận dạng 44 ARPAbet phonemes
3. **Forced alignment:** So sánh với native speaker reference

Pronunciation Analysis Pipeline

STEP 1: Phoneme Recognition (HuBERT + CTC)

Audio: "think" → // // / / /k/

User pronounced: /s/ // / / /k/

STEP 2: Forced Alignment (DTW Algorithm)

Compare user phonemes vs native reference:

Position	Expected	User	Status
1	//	/s/	SUBSTITUTION
2	//	//	CORRECT
3	//	//	CORRECT
4	/k/	/k/	CORRECT

STEP 3: Error Analysis

```
{
  "phoneme_accuracy": 0.75,
  "errors": [
    {
      "type": "SUBSTITUTION",
      "expected": "// (voiceless dental fricative)",
      "actual": "/s/ (voiceless alveolar fricative)",
      "word": "think",
      "tip": "Place tongue between teeth for 'th' sound"
    }
  ],
  "prosody": {
    "stress_pattern": "correct",
    "intonation": "slightly flat"
  }
}
```

MODEL: facebook/hubert-large-ls960 (960M params)

LATENCY: <500ms per utterance

10.6 Tầng 4: Text-to-Speech (TTS) - Chuyển Văn Bản Thành Giọng Nói

Hệ thống sử dụng 3-tier TTS để cân bằng chất lượng và tốc độ:

Tier	Model	Size	Latency	Use Case
1	Native OS TTS	0MB	<100ms	Quick feedback
2	Piper TTS (VITS)	30-60MB	100-300ms	Pronunciation demos
3	Cloud TTS	0MB	300-800ms	Premium quality

Bảng 7: TTS Tier System

10.7 Training Pipeline Chi Tiết

LoRA Training Pipeline

PHASE 1: Data Preparation

Collect domain-specific data:

- Fluency: 1,500 (EFCAMDAT)
- Grammar: 9,200 (BEA-2019, CoNLL-2014, FCE)
- Vocabulary: 2,500 (Oxford Graded Readers)
- Dialogue: 5,200 (AutoTutor, Intel/orca, Custom)

Format: Instruction-tuning template (<|im_start|>...)

Split: 70% train / 15% val / 15% test

Augmentation: Back-translation, paraphrase

PHASE 2: Environment Setup

Hardware: Mac M1/M2 32GB or NVIDIA GPU

Framework: PyTorch + Transformers + PEFT

Precision: BFloat16 (faster on Apple Silicon)

Batch: 8 (gradient accumulation 4 → effective 32)

PHASE 3: Training

Optimizer: AdamW (lr=2e-4, weight_decay=0.01)

Scheduler: Cosine with 3% warmup

Epochs: 5-7

Gradient clipping: 1.0

Early stopping: patience=3

PHASE 4: Evaluation

Fluency: MAE, Pearson correlation

Grammar: F0.5, Precision, Recall

Vocabulary: Accuracy, Macro F1

Dialogue: Human evaluation (quality, appropriateness)

PHASE 5: Production Optimization

Quantization: INT8 / INT4

Knowledge distillation: 1.5B → 0.5B

Export: ONNX / TensorRT for mobile

10.8 So Sánh Development vs Production

Component	Development	Production
Speech-to-Text		
Model	Whisper Large v3	Whisper Small
Size	1.5GB	500MB
WER	3-5%	8-10%
RAM	4GB	1.5GB
NLP Engine (Unified)		
Base Model	Qwen2.5-1.5B	Qwen2.5-0.5B
LoRA Adapters	4 × 25MB	4 × 8MB
RAM	2GB	600MB
Quality	96%	91%
Pronunciation		
Model	HuBERT-large	Server-side
Params	960M	API call
TTS		
Model	Native + Piper	Native only
Size	0-60MB	0MB
TOTAL		
RAM	6-7GB	2.4GB
Storage	3GB	1GB
Latency	~600ms	~400ms

Bảng 8: Development vs Production Comparison

11 Kết Luận

11.1 Tóm Tắt Kiến Trúc

Điểm Nổi Bật

- **Clean Architecture:** Tách biệt rõ ràng Presentation - Domain - Data
- **Feature-First:** Tổ chức code theo feature, dễ maintain
- **Dependency Injection:** Sử dụng GetIt cho loose coupling
- **Hybrid AI:** Kết hợp Cloud + On-device models
- **Cross-Platform:** Flutter cho iOS, Android, Web

11.2 Roadmap Phát Triển

1. **Phase 1 (Current):** Core features - Chat, Course, Vocabulary
2. **Phase 2:** Voice interaction - STT/TTS integration
3. **Phase 3:** Advanced AI - On-device inference với LoRA adapters
4. **Phase 4:** Social features - Leaderboard, community

11.3 Thông Tin Dự Án

Thông Tin	Chi Tiết
Version	v0.2.0
Flutter SDK	3.29+
Dart SDK	3.8.1+
Platforms	iOS, Android, Web
Repository	github.com/InfinityZero3000/LexiLingo
Branch	feature

Document generated on Ngày 15 tháng 1 năm 2026

[LexiLingo - Learn English with AI](#)